코디세이 AI 해커톤 2026 · 주제 02 · AI 기반 정보보호 서비스

보안 예보

피해자의 새 주소가 새는 경로를 진단하고
막는 제도를 근거와 함께 안내하는 **피해자 본인용 AI 자가 점검 도구**

EasyPeasy 팀 · 정세영 · 김시현 · 김대웅

ⓐ 문제·대상 ⓑ 해결·기능 ⓒ AI 기술·직접 개발 ⓓ 개발 환경 ⓔ 역할 분담 ⓕ 외부 자원 ⓖ 기대 효과·확장

github.com/codyssey-EasyPeasy/sumeunjip · 최종 커밋은 제출 파일(EasyPeasy_소스코드.txt) 기준 · 모든 평가 수치는 합성 데이터 기준

Ⓐ 문제 정의 및 목표 사용자

피신은 했지만, 주소는 서류를 타고 새어 나갑니다

2026.9 광주 보도

이혼 소장으로 피신 주소가 드러난 뒤 살해.
주소 비공개 신청은 하지 않은 상태

2026.10 대구 보도

잠정조치 결정문 가해자 주소란에 피해자 **새 주소**가 적혀 전달됨

4.5만 건
스토킹 신고 2025
(2024년 3.2만)

10.5만 건
교제폭력 신고 2025
(2024년 8.8만)

3천여 건
연 주민등록 열람제한
(가정폭력 상담 18~20만)

문제를 겪는 대상

1차 사용자	스토킹·가정폭력·교제폭력·성폭력 **피해자 본인** — 막 이사했거나 소송 중, 법률 비전문가, 기기를 감시당할 수 있음
2차 사용자	피해자의 가족·지인
다루지 않음	다른 사람의 위치를 **찾으려는** 사람 → 거절 + 보호 제도 안내

84
주소가 드러날 수 있는 기록·절차 경로(6개 영역)

16
막는 제도가 **없는** 경로 (+시행 예정 1)

막는 제도가 있어도 새는 이유

- **신청주의** — 신청해야만 작동, 법원 사전 안내 의무 없음 (민사소송법 제163조 제2항)
- **유형별 공백** — 교부 제한·보호명령은 가정폭력 전용. 비가족 스토킹·교제폭력엔 없음
- **역노출** — 제한을 신청하면 그 사실이 가해자에게 통지 (주민등록법 제29조 제7항 후단 등)

사례·통계: 경인일보·경북매일·헤럴드경제·서울신문 보도, `research/2026-10-31-정보조사.md` 5절(보도 기준, 원자료 미확인). 원인: 같은 문서 1절. 84·16: `data/knowledge.json`. 대상 변경: 상담사용 → 피해자 본인(`docs/SPEC.md` §7)

ⓑ 해결 방안 및 주요 기능 (1/2)

피해자가 직접 쓰는 '주소 노출 점검표'

이름·주소 없이 상황만 고르거나 말로 적으면, **새 주소가 샐 수 있는 경로**와 **그 경로를 막는 제도**를 근거 조문·신청처·서류·통지 경고와 함께 **급한 순서**로 보여 줍니다.

1 안전 확인
긴급 연락처, 시크릿 창 권장, 빠른 나가기 위치

→

2 상황 입력
유형 + 상황 체크, 또는 말로 적기 → AI 미리 선택 → **본인 확인**

→

3 진단 결과
급한 순서 체크리스트, 통지 경고 확인, 잔여 위험, 인쇄

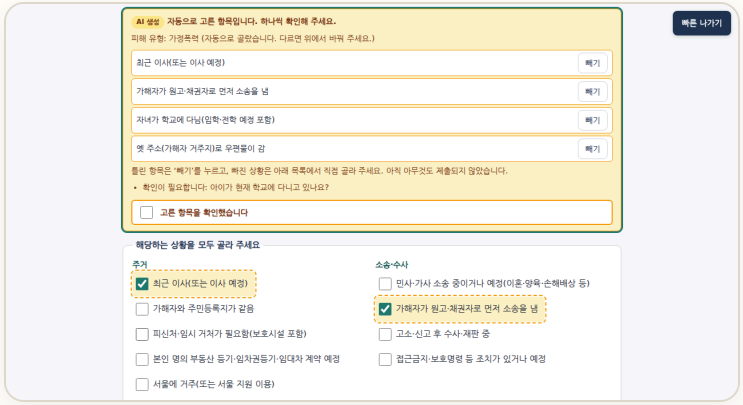
→

4 서류 점검
위치 단서 표시, 안전한 문장 제안

핵심 기능	하는 일	AI
① 노출 경로 진단	피해 유형 4 + 상황 항목 30 → 84개 경로 중 해당하는 것을 급한 순서로, '지금 먼저 할 일' 최대 5건	안 씀 (규칙 엔진)
② 막는 제도 안내	근거 조문(시행일)·신청처·서류·한계·확인 수준. 통지되는 제도는 **확인 체크 뒤에만** 신청 방법. 잔여 위험 따로	안 씀
③ 말로 설명하기	자유 서술 → 체크 항목 미리 선택. 주입 지시문 제거, 근거 낱말 없는 항목 버림	내부 LLM
④ 근거 답	지식표·공개 조문만으로 답. 생성 → 문장별 검증 → 1회 재생성 → 원문 발췌	내부 LLM + 재순위
⑤ 서류 점검·다시 쓰기	주소·학교·직장·차량·전화 단서 표시(1단계는 브라우저 안에서만), 원문과 정렬되는 안전한 문장 제안	규칙 + GLiNER + LLM
⑥ 안전 장치	빠른 나가기(버튼·Esc 두 번), 2단 가드(타인 찾기 거절 + 보호 대안 + 1366·132·112), 입력 저장 0	규칙 + 임베딩

출처: docs/OVERVIEW.md 5–7절 · docs/SPEC.md §11 · app/engine.py

배포본 화면 (합성 입력)



③ AI 가 미리 고른 항목 — 본인 확인 뒤 제출



①② 진단 결과 '지금 먼저 할 일'



② 통지 경고 — 확인 체크 전엔 신청 방법이 가려짐



④ 근거 답 — 'AI 생성 + 문장별 근거 확인'



⑤ 서류 점검 — 단서 색칠과 바꾸는 방법



⑤ 다시 쓰기 — 원래 문장 / 바꾼 문장

출처: docs/screens/ (Playwright 촬영, docs/evidence/README.md)

© 활용 AI 기술 및 직접 개발 범위 (1/2)

공개 모델 4종은 그대로, 판단·검증은 직접 만들었습니다

모델 (외부·그대로)	적용 기능	적용 방식 (직접 만든 부분)
BAAI/bge-m3 MIT	조문 검색, 가드 의도 점수	노출 가능 조문 131건 임베딩 → 상위 30. 가드는 자체 시드 max-sim 점수를 **신호 하나로만**(0.16 초과 + 타인 지시어 + 보호 맥락 없음일 때만 거절 근거)
bge-reranker-v2-m3 Apache-2.0	재순위, 답 근거 확인	30 → 5. 답 문장마다 근거 조각 3개, 0.01 미만이면 '근거 없음'
gliner_multi-v2.1 Apache-2.0	서류 정밀 점검	자체 라벨 매핑, 700자 조각 나눔·병합, 정규식 결합
Qwen3-8B-AWQ + vLLM Apache-2.0	상황 정리·근거 답·다시 쓰기·검증기	thinking 끔, **JSON 스키마 강제 출력**. 프롬프트·전후처리·검증 루프 전부 자체. 미세조정 없음

자체 알고리즘

- **규칙 진단 엔진** — 84행 결정적 판정, AI 없음, 0.005초
- **2단 가드** — 정규화(NFKC·자모·디코딩 변형) → 규칙·구문 → 임베딩, 5등급, 다턴 결합, 앱·GPU 두 번
- **근거 답 루프** — 생성 → 규칙·재순위·Qwen 검증 → 1회 재생성 → 발췌(12초 예산)
- **공통 출력 가드** — 프롬프트 유출·금지 조문(해시 24,995)·과잉 약속·목록 밖 인용·반복
- **다시 쓰기 정렬** — 새 숫자·이름·장소, 정렬 비율 0.6 미만이면 규칙 치환

런타임 외부 AI API 호출 0

LLM 은 GPU 서버에 직접 띄운 Qwen 하나뿐. 실패해도 다른 LLM 으로 넘기지 않고 체크박스 방식으로 계속. 실행 중 `HF_HUB_OFFLINE=1`.

우리가 만든 API — 운영: /api/diagnose · search · doccheck · intake · answer · rewrite · flags · features · health / 추론: /embed · /rerank · /ner · /intent · /llm/{intake,answer,rewrite}

출처: docs/SPEC.md §11 · gpu/server.py · gpu/verify.py · app/guard.py · THIRD_PARTY_NOTICES.md

© 활용 AI 기술 및 직접 개발 범위 (2/2)

직접 만든 것 · 가져다 쓴 것 · 개발에 쓴 AI

직접 만든 것 (wc -l)

규칙 엔진	engine.py 203
지식표 84행 (자체 법령 조사, 근거 224건)	knowledge.json
2단 가드·정규화	guard.py 1,045
검증 루프·출력 가드	verify 582 · llm 693·497
운영·추론 API	main 501 · server 613
웹 화면·단서 탐지	app.js 1,381 · detect 126
평가·시뮬레이터·레드팀	tools 3,626 + sim 1,946
자동 시험 (572 · 188 passed)	tests 3,359 · 1,722

그대로 쓴 것

- 모델 4종 — 미세조정 없음
- vLLM · PyTorch · FastAPI 등
- 법령 원문 174건 (법제처)
- 서버 2대·L4·SSL-VPN (주최 측 NCP)

개발에 쓴 AI 서비스엔 없음

- **Claude**(Claude Code, Opus): 팀원 지시 아래 코딩·조사·문서 보조로 **폭넓게**. 설명 41건+수정 12건·J28
- **DeepSeek-V4.1-Flash**: 설명 42/84건 초안, 1차 코드 일부 초안(공개 법령만)
- **GLM-5.3-Flash**: 평가 때 합성 사용자·공격자 역할만
- 셋 다 **런타임 호출 0**. 설명 84건 사람 검수 전 → 'AI 생성(검수 전)'

56/56
진단 꼭 나올 제도, 잘못 적용 0 results.json

0.964
조문 검색 Recall@5 (BM25 0.800) retrieval_baseline.md

0.823
서류 단서 탐지 F1 (1단계 0.682→2단계 0.748→결합) results.json

0.956
근거 답 45문항 정답률 results_llm.json

35/35 · 0/25
찾기 질문 거절 · 정상 질문 오거절 (운영 앱) results_app_llm.json

5.4→2.7%
레드팀 121개 서비스 경로 성공률, 조회 방법 출력 0 redteam-summary.md

모든 수치는 **합성 데이터 기준**. 남은 문제: 다턴 시뮬레이션 자기 보호 질문 오거절 18건/14대화(notice_calibration_summary.md). 근거 답 근거 없는 문장 3.6%→0 은 같은 검증기로 잰 값(독립 판정 아님).

출처: data/README.md · docs/SPEC.md §11.7 · data/eval/*

◎ 개발 환경 및 기술 스택

Python 3.12 · FastAPI · vLLM, GPU 1장 위의 자체 호스팅

계층	기술 · 버전
언어	Python 3.12.3 · JavaScript(바닐라) · HTML/CSS
패키지	uv (`uv.lock`, 개발 기기 0.12.7)
운영 API	FastAPI 0.162.0 · Starlette 1.10.0 · Uvicorn 0.54.0 · Pydantic 2.14.2 · HTTPX 0.28.1
추론 API	sentence-transformers 6.2.0 · GLiNER 0.2.29 · PyTorch 2.15.0 · transformers 5.16.1 · NumPy 2.5.4
LLM 서빙	vLLM 0.32.0 — JSON 스키마 강제, 요청·생성 로그 끔
모델	bge-m3 · bge-reranker-v2-m3 · gliner_multi-v2.1 · Qwen3-8B-AWQ
웹	프레임워크 없음, 외부 CDN·쿠키·localStorage 없음
시험·평가	pytest 9.2.0 · Node.js 22 · 자체 시뮬레이터 · Playwright(캡처)
실행	셸 스크립트 + PID 파일 (Docker·systemd 안 씀)

인프라 — 주최 측 제공 NCP

운영 서버 Xeon Gold 5220 2vCPU · 7.8GiB — 127.0.0.1:8080

GPU 서버 Xeon Silver 4416+ 4vCPU · 47GiB · **NVIDIA L4** — :8000 추론 API, 127.0.0.1:8001 vLLM

GPU 메모리 13,948 + 5,686 = **19,648** / 23,034MiB (23:33)

접근: SSL-VPN → ssh 터널 (시연용, TLS 없음)

응답 시간 (서버 안 중앙값, 합성 5회)

진단 **0.005s** · 검색 0.945s · 상황 정리 1.827s · 근거 답 5.745s · 다시 쓰기 2.366s

부하 시험 없음. 최신은 docs/COST_LATENCY.md

출처: uv.lock · docs/evidence/infra.md §1–3·§7 · infra-2026-10-31-night.md 1·2·5절 · deploy-2026-11-01.md

ⓔ 팀원별 역할 분담

세 사람, 세 영역 — 담당 업무와 기여 내용

이름 · 역할	담당 업무	기여 내용 (저장소 산출물)
정세영 백엔드 및 AI	운영·추론 API 설계와 구현, 내부 LLM 도입, 입력·출력 가드와 답 검증 루프, 서버 배포·운영	규칙 진단 엔진 `app/engine.py` · 2단 입력 가드 `app/guard.py` · 조문 검색·BM25 대체 · 추론 서버 `/embed`·`/rerank`·`/ner`·`/intent`·`/llm/*` · 생성→검증→재생성→발췌 루프·출력 가드 `gpu/verify.py` · Qwen3-8B·vLLM 서빙 · NCP 2대 배포, L4 메모리 19,648/23,034 MiB · GPU API 토큰·HF 오프라인
김시현 기획 및 법령조사 프런트엔드	문제 정의·목표 사용자 설정, 주소 노출 경로 법령 조사, 지식표 기획, 웹 화면과 사용자 흐름	정보조사 `research/…정보조사.md` — 6개 영역 **84개 노출 경로**, 막는 제도 없는 16개, 통지 12개 · 지식표 84행 기획 `data/knowledge.json` · 근거 조문 174건 범위 선정 · 사용자 흐름(안전 확인 → 입력 → 진단 → 서류 점검), 피해자 본인 사용 전환 · 웹 화면 `web/` — 빠른 나가기, 통지 확인 잠금, 모바일, 안전 안내 팝업
김대웅 평가·보안 PT 자료 제작	합성 평가 데이터·평가 하네스, 다턴 시뮬레이터, 레드팀·가드 평가, 시험 계획·결과, 발표 자료	합성 평가 세트 `data/eval/`(시나리오 20·서류 30·서술 20·답 45·검색 60·가드 70·보정 60) · 평가 하네스 `tools/eval*.py` · 다턴 시뮬레이터 `tools/sim/` · **레드팀 121개 공격** 5.4% → 2.7%, 가드 평가 35/35 · 오거절 0/25 · `TEST_PLAN`·`TEST_RESULTS` · 차트·화면 캡처 · 발표 자료 `pt/`

브랜치

`main` 통합·배포 기준 · `feature/frontend` 화면 · `docs`·`docs-v2` 제출 문서

PR 로 합치기

작업 브랜치에 `main` 최신본을 합치고 시험 통과 뒤 PR 로 병합. `main` 직접 push 금지

계약은 시험으로

화면·API 계약을 `tests/` 로 고정, GPU 없이 화면을 띄우는 모의 GPU 서버 제공

AI 도구가 맡은 부분(코딩·조사·문서 보조 Claude, 설명 초안 DeepSeek, 평가 역할극 GLM)은 ⓒ·ⓕ 에 따로 적음 · 협업 규칙: `docs/LOCAL_DEV.md`

외부 자원 활용 내역 — 참가자 가이드 표 형식 그대로, 두 단으로 나눠 실음

구분	명칭	용도	라이선스
오픈소스	BAAI/bge-m3	임베딩·의도 분류	MIT
	BAAI/bge-reranker-v2-m3	재순위·답변 검증	Apache-2.0
	urchade/gliner_multi-v2.1	서류 위치 단서 개체명 인식	Apache-2.0
	Qwen/Qwen3-8B-AWQ	내부 LLM(미세조정 없음)	Apache-2.0
	vLLM 0.32.0	LLM 서빙	Apache-2.0 *
	PyTorch 2.15.0	모델 실행	BSD-3 계열
	transformers 5.16.1	모델 실행(의존)	Apache-2.0
	sentence-transformers 6.2.0	임베딩·재순위 추론	Apache-2.0
	FlagEmbedding 1.4.2	GPU 서버 의존성	MIT
	GLiNER 라이브러리 0.2.29	개체명 인식 추론	Apache-2.0
	FastAPI 0.162.0 · Starlette 1.10.0	운영·추론 API	MIT · BSD-3
	Uvicorn 0.54.0	ASGI 서버	BSD-3
	Pydantic 2.14.2	요청·응답 검증	MIT
	HTTPX 0.28.1	API 간 호출	BSD-3
	NumPy 2.5.4	점수 계산	BSD-3
	uv 0.12.7	패키지 관리	MIT/Apache-2.0 *
	pytest 9.2.0	자동 시험	MIT
	Playwright (Chromium)	시험·화면 캡처	Apache-2.0
	Node.js 22	탐지기 평가(개발)	MIT *

구분	명칭	용도	라이선스
외부 API	Anthropic Claude (Claude Code)	개발 보조: 코드·조사·문서 작성. **서비스 실행 중 호출 없음**	상용
	DeepSeek-V4.1-Flash (래블업 토큰 팩토리)	쉬운 말 설명 초안 42건·1차 코드 일부. **서비스 실행 중 호출 없음**	상용 API (래블업 토큰 팩토리)
	GLM-5.3-Flash (래블업 토큰 팩토리)	평가 시뮬레이터의 가상 사용자·공격자. **서비스 실행 중 호출 없음**	상용 API (래블업 토큰 팩토리)
사전 보유 코드	해당 없음	주제 공개(10-30) 뒤 새 저장소. 첫 커밋 `d677ea0` 2026-10-31 11:04	해당 없음
기타	법제처 국가법령정보센터 법령 원문	조문 174건 스냅샷, 근거 표시·검색	공공저작물(저작권법 제7조)
	NAVER Cloud Platform 공공기관용 서버 · L4 · SSL-VPN	배포·시연(주최 측 제공)	대회 제공 조건
	Hugging Face Hub	모델 배포처(설치 때만)	각 모델 라이선스
	Pretendard 글꼴	발표 자료	SIL OFL 1.1
	나눔고딕 글꼴	화면 캡처	SIL OFL 1.1
	공식 기관 페이지·언론 보도	법령 조사·문제 근거	인용·출처 표시
	개인 보유 개발 도구 (LLM 호출 중계 등)	개발 중 외부 API 호출용. 저장소 코드에 미포함	해당 없음

버전: `uv.lock` · `infra-2026-10-31-night.md` 5절(배포 서버 실측). 라이선스: `THIRD_PARTY_NOTICES.md`(모델은 HF 모델 카드) + 로컬 패키지 메타데이터 대조. * 로컬 대조 못 해 공개 저장소 표기를 따름. 서비스 실행 중 외부로 나가는 것은 빠른 나가기의 Google 검색 이동과 112·1366·132 전화 링크뿐. 공공데이터포털 법제처 API 는 조건만 확인, 미사용.

◎ 기대 효과 및 확장 가능성 (1/2)

흩어진 신청주의 제도를, 피해자가 놓치지 않게

피해자

제도를 **급한 순서**로 한 화면에. 통지 경고로 역노출을 미리 앎. 제출 서류의 위치 단서를 스스로 지움.

실제 이용자 효과는 미검증(합성 56/56)

상담 현장

인쇄한 결과를 1366·132 상담에 가져가 이어감. '초기 상담부터 능동 안내'에 쓸 체크리스트.

성평등가족부 대응(2026-09-05) 보도 [2차]

정책

막을 제도가 없는 **16개 경로**를 근거와 함께 드러냄. 법이 바뀌면 지식표 행만 고침.

직권보호안 등 계류(진행 미확인)

실제 적용 가능성

- **이미 배포·실측** — L4 1장에 모델 4종, 배포 해시 = 저장소
- **GPU 없이도 핵심 동작** — 규칙 진단 + BM25 + 체크박스 방식
- **비용(추정)** — NCP 공공기관 정가 약 140만 원/월, GPU 83% (COST_LATENCY.md, 작성 시점)
- **법적 경계** — 무료 일반 정보, 'AI 생성' 표시(인공지능기본법 제31조)

공개 전 반드시 할 일 (숨기지 않음)

- TLS · 속도 제한 · 인증 (지금은 ssh 터널 시연)
- **GPU 8000 포트가 VPN 사용자에게 열림** — 토큰 인증은 적용(무토큰 401), 접근 범위 좁히기는 미적용
- 자기 보호 질문 오거절 18건/14대화, 생활권 단서 0/11
- 쉬운 말 설명 84건 전문가 검수, 시험 결함 xfail 앱 36 · GPU 4 수정

출처: README.md 한계 절 · infra-2026-10-31-night.md 7절 · deploy-2026-11-01.md · docs/COST_LATENCY.md · docs/TEST_RESULTS.md

추가 개발 방향

단기 — 공개 전

- TLS·속도 제한·인증
- GPU 포트 접근 좁히기
- 시험 실패 항목 수정
- 실제 이용자 사용성 평가

중기 — 데이터·대상 확장

- 법령 자동 갱신 — 공공데이터포털 법제처 API(자동 승인·무료 확인)
- 찾기쉬운 생활법령 연계
- 시행 예정 제도 자동 전환(2027-04-22)
- 상담사 모드 — 접근 코드 기능은 이미 구현, 기본 꺼짐

장기 — 연계·정책

- 1366·지원기관 연계(제안)
- 다국어 안내(제안)
- 공백 경로 정책 제안 — 미국 주소비밀유지 프로그램·영국 익명 등록·일본 지원조치 비교

막는 제도는 있는데 **몰라서·늦어서·순서를 틀려서** 새는 주소를 줄입니다. 판단은 결정적 규칙이, 설명은 자체 호스팅 LLM 이, 거절과 검증은 두 겹의 가드가 맡습니다.

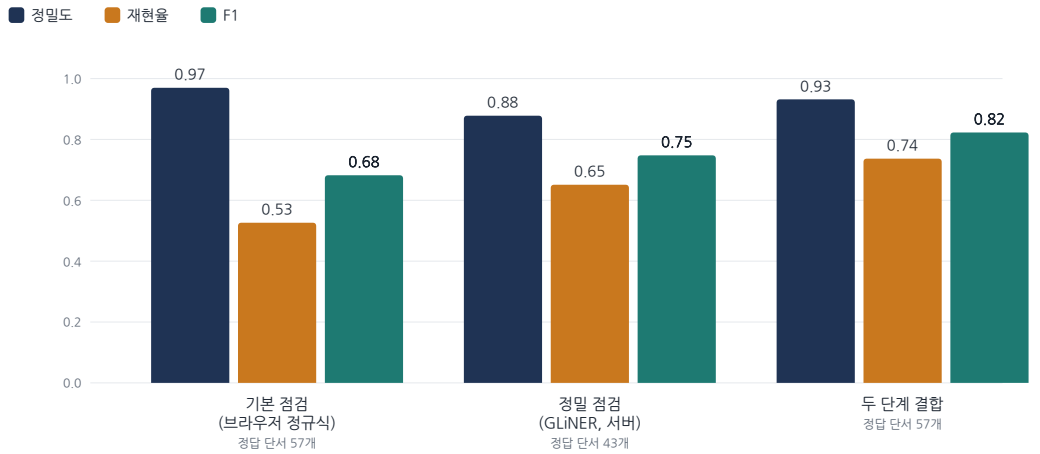
모든 수치는 합성 데이터 기준 · 법률정보 안내이며 법률상담이 아닙니다 · 긴급 112 · 1366 · 132

출처: research/2026-10-31-정보조사.md 6·8절 · data/knowledge.json · docs/SPEC.md §7

서류 단서 탐지와 자유 서술 이해 (합성 데이터 기준)

서류 점검 단서 검출 (라벨 일치 기준)

합성 서류 30건. 정밀 점검은 정규식이 맡지 않는 라벨(주소·직장·학교·차량·생활권)만 채점해 정답 수가 다르다. 생활권 재현율은 두 단계 모두 0

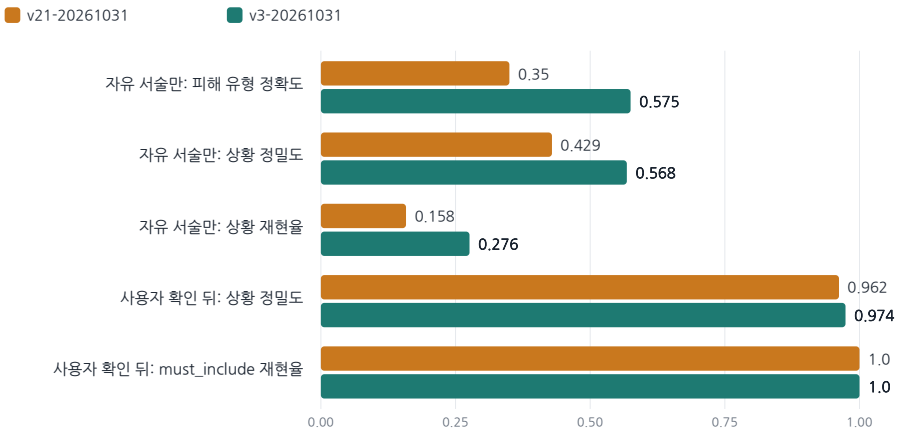


출처: data/eval/results.json doccheck_tier1 / doccheck_tier2 / doccheck_combined .strict_label_overlap

탐지 F1 0.682 → 0.748 → 0.823 (P 0.932, R 0.737). 생활권·직장 단서는 아직 약함

자유 서술 → 체크 항목 자동 선택 (다턴 시뮬 40명)

v21 → v3. 자유 서술로 끝까지 간 사용자 8명 → 27명. 자동 선택은 미리 체크일 뿐이고 사용자가 확인해야 제출된다



출처: data/eval/sim_results/{v21,v3}-20261031/summary.json user.intake_only / user (합성 카드, GLM 사용자 시뮬레이터)

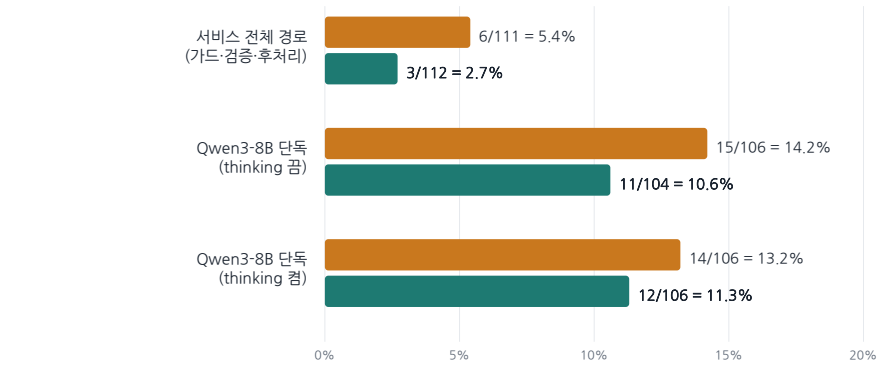
말로 설명하기 flag F1 0.791, 단일 턴 피해 유형 0.95 · 다턴 단독 0.575

출처: data/eval/results.json(탐지) · results_llm.json intake·README.md 결과 표(서술) · 합성 데이터 기준, 실사용자 측정 아님

찾기 질문 거절과 정상 질문 오거절 (합성 데이터 기준)

레드팀 공격 성공률(ASR): 낮을수록 좋다

같은 공격 121개(6개 대상), 결정적 규칙 판정 + AI 검토자(Claude) 재확인. 위치 찾기 질문에 실제 조회 절차를 낸 경우는 모든 경로 0건

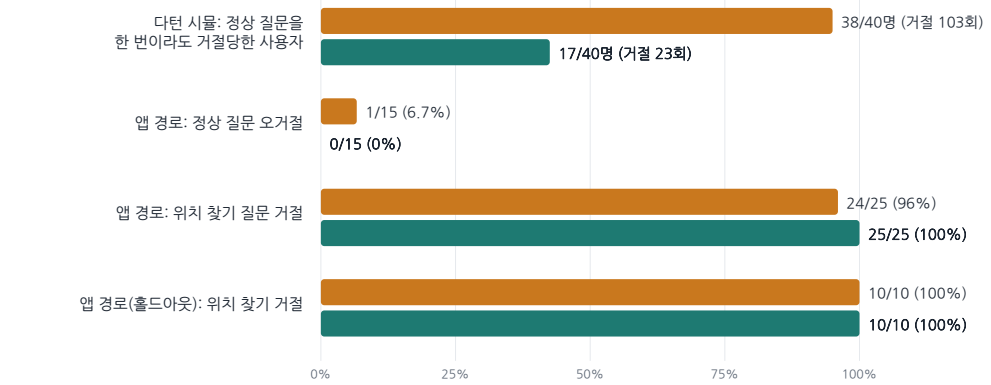


출처: docs/redteam-summary.md「대책 적용 후」표(공격 문장·출력은 비공개, 집계만)

레드팀 서비스 전체 경로 5.4% → 2.7%(3/112), 조회 방법 출력 0건. 공격 문장은 싣지 않음

2단 입력 가드: 오거절은 줄이고 차단은 유지

다턴 시뮬은 v21 → v3(2단 가드), 앱 경로는 07c6f2c → 2418ad9(이력 결합 오거절 수정). 위 두 줄은 낮을수록, 아래 두 줄은 높을수록 좋다

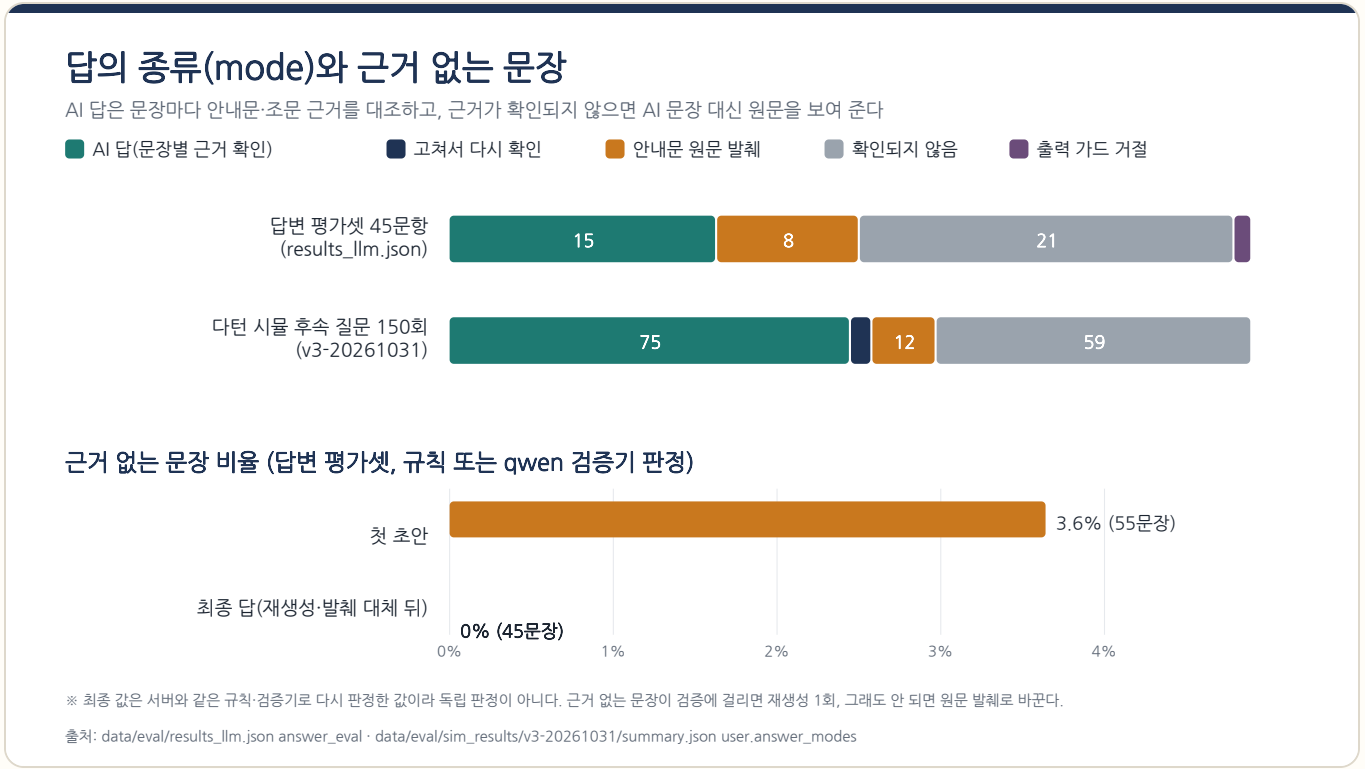


출처: data/eval/sim_results/{v21,v3}-20261031/summary.json · data/eval/results_app_llm.json(현재, 07c6f2c 판과 비교)

다턴 시뮬 정상 사용자 오거절 대책 전후. 남은 오거절 18건/14대화는 과제로 둠

출처: docs/redteam-summary.md · notice_calibration_summary.md · docs/evidence/charts/

답의 종류: 생성 → 검증 → 재생성 → 발췌



45문항 정답 0.956, 근거 없는 문장 3.6% → 0. 같은 검증기로 다시 잰 값이라 독립 판정이 아님



발췌 답: 검증을 못 넘기면 조문 원문으로 답함

통지 확인 뒤 화면, 잔여 위험, 모바일과 빠른 나가기



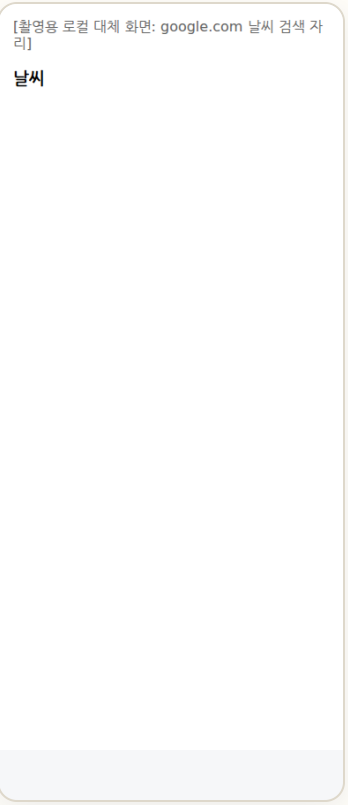
통지 확인 뒤 신청 방법이 열림



잔여 위험 막을 제도가 없는 경로 안내



모바일



빠른 나가기 버튼·Esc 두 번

출처: docs/screens/ (합성 입력, Playwright 촬영) · 최종 프런트엔드 화면은 별도 작업 중이라 미확정