코디세이 AI 해커톤 2026 · 주제 02 · AI 기반 정보보호 서비스

보안 예보

가장 위험한 개인정보, 피해자의 새 주소가 새는 84개 경로를 먼저 진단하는 정보보호 AI

해킹이 아니라 **합법적인 행정·사법 절차로 새는 개인정보**를 막습니다

입력 저장 0 | 서비스 실행 중 외부 AI 호출 0 | 타인 위치 찾기 거절

EasyPeasy 팀 · 정세영 백엔드·AI · 김시현 기획·법령조사·프런트 · 김대웅 평가·보안·PT

github.com/codyssey-EasyPeasy/boan-yebo

피신해도 새 주소는 해킹이 아니라 소장·결정문·통보서로 샙니다 — 공식 경로 84개 중 16개는 막을 제도조차 없습니다

2026.9 광주 이혼 **소장**으로 피신 주소가 드러난 뒤 살해 — 주소 비공개 신청은 안 한 상태 보도

2026.10 대구 잠정조치 **결정문** 가해자 주소란에 피해자 새 주소가 적혀 전달 보도

2025.8 서울 강서 경찰이 스토킹 **통보서**를 가해자 휴대전화로 오발송 보도

→ 셋 다 해킹이 아니라 서류로 샜습니다

목표 사용자

1차	스토킹·가정폭력·교제폭력·성폭력 **피해자 본인** — 막 이사했거나 소송 중, 법률 비전문가, 기기를 감시당할 수 있음
2차	대신 찾아봐 주는 가족·지인
막는 사람	남의 위치를 **찾으려는** 사람 → 거절 + 보호 제도 안내

84

유출 경로 — 새 주소가 드러날 수 있는 기록·절차(6개 영역)

16

차단 통제 없음 — 막는 제도가 없는 경로 = 잔여 위험

통제가 있어도 기본값은 '노출'

- **신청주의** — 신청해야만 작동, 미리 안내할 의무 없음
- **유형별 공백** — 교부 제한·보호명령은 가정폭력 전용
- **역노출** — 제한을 신청하면 그 사유가 가해자에게 통지

43.9만 건 관계성 범죄 신고, 2025년 — 전년 대비 +23.1%

사례: 경인일보·경북매일·YTN 보도 · 신고 통계: 성평등가족부·경찰청 공동 발표(2026-05-18) · 84·16: 자체 법령 조사 지식표(법령 원문 대조) · 상세 출처 docs/SUBMISSION.md ⓐ

이름도 주소도 묻지 않습니다 — 상황만 고르면 새 주소의 유출 경로와 막을 제도를 급한 순서로 보여 줍니다

1

안전 확인

안전 안내 팝업, 긴급 띠

112·1366·132

감시당하는 기기일 수 있다 → **빠른 나가기**

→

2

상황 고르기

체크하거나 말로 적기 → AI 가 미리 고름 → **본인 확인**

무엇을 말해야 할지 몰랐다 → **상황만 고르면 됨**

→

3

진단

'지금 먼저 할 일', 카드는 위험 → 도움, 통지 경고

어디서 샐지 몰랐다 → **경로와 순서를 앎**

→

4

서류 점검

제출할 초안의 위치 단서 표시, 안전한 문장 제안

내 서류가 주소를 흘렸다 → **내기 전에 지움**

핵심 기능	하는 일	판단 주체
① 노출 경로 진단	피해 유형 4 + 상황 30 → 84개 경로 중 해당하는 것을 급한 순서로	**결정적 규칙** (의도적: 틀리면 위험한 판단은 AI 배제)
② 막는 제도 안내	근거 조문(시행일)·신청처·서류. 통지되는 제도는 **확인 체크 뒤에만** 신청 방법	**결정적 규칙** (같은 입력 → 같은 결과)
③ 말로 설명하기	자유 서술 → 체크 항목 미리 선택(JSON 스키마)	자체 호스팅 LLM 제안 → **본인이 확정**
④ 근거 답	공개 조문만으로 설명, 문장마다 근거 확인, 실패 시 원문 발췌	LLM 설명 + 근거 검증 통과분만
⑤ 서류 점검·다시 쓰기	주소·학교·직장·차량·전화 단서(1단계는 브라우저 안에서만)	규칙 + 개체명 모델 + LLM
⑥ 안전 장치	빠른 나가기(버튼·Esc 두 번)·긴급 띠·찾기 질문 거절 + 보호 대안	규칙 + 임베딩 신호(2단 가드)

안전 설계 4원칙 ① 감시당하는 기기 전제(저장 0·빠른 나가기) ② 역노출 방지(통지 경고 확인 뒤 신청 방법) ③ 찾기 거절 + 보호 대안 ④ 막는 법만, 찾는 법은 말하지 않음

→ AI 가 틀려도 권할 제도는 바뀌지 않습니다

가장 위험한 순간 — '신청했더니 가해자에게 통지됐다'를 신청 전에 막습니다

⚠ 신청하면 상대에게 알려질 수 있습니다

제한을 신청하면 그 사유가 제한대상자(가해자)에게 서면으로 통지됩니다(주민등록법 제29조 제7·8항 후단). 통지가 가기 전에 안전계획을 세우고, 통지 내용에 새 주소가 드러나지 않는지 담당자에게 확인하세요.

☐ 상대에게 알려질 수 있다는 점을 확인했습니다

시기 전입신고와 같은 방문에서(전입 직후 제한 전 공백을 줄인다)

위 경고를 확인하면 쉬운 설명과 신청 방법이 보입니다.

① 체크 전 — "신청하면 상대에게 알려질 수 있습니다" 를 확인해야 신청 방법이 열립니다

⚠ 신청하면 상대에게 알려질 수 있습니다

제한을 신청하면 그 사유가 제한대상자(가해자)에게 서면으로 통지됩니다(주민등록법 제29조 제7·8항 후단). 통지가 가기 전에 안전계획을 세우고, 통지 내용에 새 주소가 드러나지 않는지 담당자에게 확인하세요.

☑ 상대에게 알려질 수 있다는 점을 확인했습니다

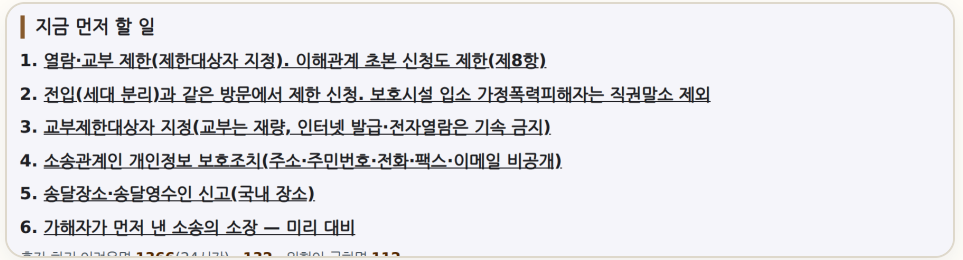
시기 전입신고와 같은 방문에서(전입 직후 제한 전 공백을 줄인다)

이 제도로 받을 수 있는 도움

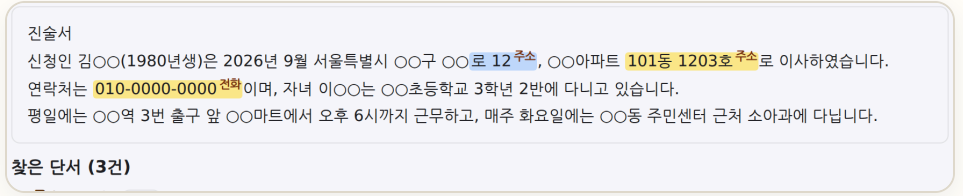
AI 생성(검수 전)

가정폭력 피해자가 읍·면·동 주민센터에 직접 나가 신청하면 지정한 사람에게 내 주민등록 등·초본 열람·교부를 막아 줘요. 본인이 출석하면 즉시 처리되고 수수료는 없어요. 다만 주민등록지가 가해자와 같으면 신청할 수 없고, 지정한 사람만 차단되며 제한 사유가 가해자에게 서면으로 통지돼요.

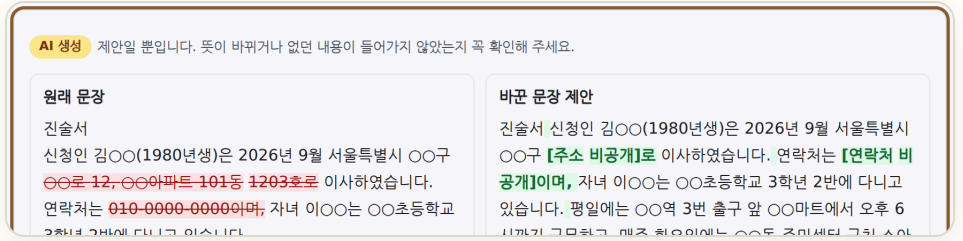
② 확인 뒤 — 쉬운 설명·신청처가 열림. 통지를 알고, **신청 전에** 안전계획을 세웁니다



진단 '지금 먼저 할 일' — 무엇부터 할지 급한 순서로



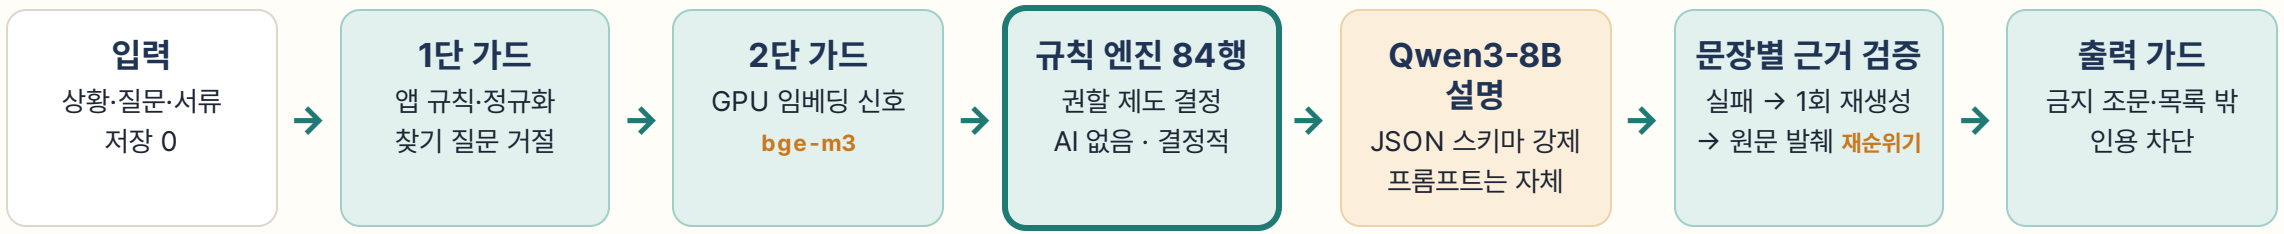
서류 점검 내 서류 속 주소·전화 단서를 색칠



다시 쓰기 단서를 지운 문장 제안 — 'AI 생성' 표시, 본인이 확인

나머지 화면(AI 미리 선택·근거 답·찾기 거절·모바일)은 시연 영상과 부록 A3·A4

AI 는 판단하지 않습니다 — 제도는 규칙이 정하고, AI 문장은 근거 검증을 통과해야 나가며, 피해자의 글은 우리 GPU 밖으로 나가지 않습니다



직접 설계·구현 · 공개 모델 그대로(미세조정 없음) · **런타임 외부 AI 호출 0 · NVIDIA L4 1장 자체 호스팅**

위협 모델 — 도구 자신이 새 유출 경로가 되지 않게

위협	막는 장치
① 가해자가 피해자 위치를 찾으려 도구를 씀	2단 가드, 막는 법만 출력, 서비스에 개인 위치 데이터 0
② 가해자가 피해자 기기를 감시	입력 저장 0·쿠키·localStorage 0, 빠른 나가기(Esc 두 번)
③ 서류 속 지시문(간접 주입)	지시문 제거·JSON 스키마 강제·출력 가드
④ 진술이 외부로 반출됨	외부 AI 호출 0, 실행 중 모델 허브 오프라인, 로그엔 입력 없음

공개 모델 4종 — 맡은 일 | 우리가 만든 부분

bge-m3	조문 검색·가드 신호 | 신호 하나로만 쓰는 판정 규칙
bge-reranker	재순위·근거 확인 | 문장별 근거 판정 루프
GLiNER	서류 단서(백본 mDeBERTa) | 라벨 정의·긴 문서 조각 병합·정규식 결합
Qwen3-8B-AWQ	설명·상황 정리·다시 쓰기 | 프롬프트·검증·재생성·발췌 전부

AI 가 맡는 일 자유 서술 이해 · 조문 검색·재순위 · 서류 단서 탐지 · 근거 검증형 설명

맡기지 않는 일 권할 제도 결정(틀리면 위험)

모델·임계값·API 상세: docs/SUBMISSION.md ⓒ · docs/SPEC.md §11

우리가 만든 것은 검증 장치입니다 — 그 장치가 우리 기능 하나를 출시에서 막았습니다

설계 결정 4개와 실측 근거

1. **권고는 LLM 이 아니라 규칙이 정합니다.** 결정적, 0.005초, 같은 입력엔 같은 결과
2. **품질 게이트 0.90.** '검색 답 종합'은 보류 세트 0.625로 미달 → **출시 안 함.** 1~3라운드 모두 기준 미달
3. **가드를 앱과 GPU 로 나눴습니다.** GPU 가 없어도 1단 규칙 가드는 계속 동작
4. **작은 이득도 그대로 공개합니다.** 재순위기 이득은 R@5 0.945 → 0.964, 1문항

개발에 쓴 AI(서비스엔 없음): Claude Code 코딩·조사·문서 보조(폭넓게) · DeepSeek 설명 초안 42/84 · GLM 평가 역할극. 쉬운 말 설명 사람 검수 0/84 → 화면에 'AI 생성(검수 전)'

모든 수치는 합성 데이터 기준입니다

안전

3/84 개발
레드팀 검색·답 경로 84건 중 가드 통과 3.6% (95% 1.2–10.0%, 배포본) · **위치 조회 방법 출력 0**

35/35 · 0/25 조정
찾기 질문 거절 · 정상 질문 오거절

정확

0.964 보류
조문 검색 Recall@5

56/56 개발
진단 꼭 나올 제도

0.956 개발
근거 답 45문항

0.823 개발
서류 단서 F1

미출시 0.625 < 0.90 보류
검색 답 종합 — 게이트가 우리 기능을 막았습니다

통과한 레드팀 응답은 공개 조문이나 '찾지 못함'뿐 — 서비스에 개인 위치 데이터가 없습니다. 대책 전후는 같은 세트라 개선을 주장하지 않습니다. 남은 약점: 자기 보호 질문 오거절(다턴 18/225 응답). 자동 시험 앱 598 · GPU 188 통과

세트 배지 — 보류: 조정에 안 쓴 세트 · 개발: 만들며 본 세트 · 조정: 규칙을 맞춘 세트 · 출처 docs/EVIDENCE.md 0절

GPU 한 장(L4) 안에서 모든 AI 가 돕니다 — 외부 AI 로 나가는 연결 0, GPU 가 없어도 핵심 진단은 됩니다

브라우저
쿠키·localStorage·외부 CDN 0 · 서류 1단계 점검은 브라우저 안에서만

↓

운영 서버 NCP · Python 3.12 · FastAPI
규칙 엔진 · 1단 가드 · 화면. GPU 가 없으면 BM25 검색 + 체크박스로 계속

↓ 공유 토큰

GPU 서버 NCP · NVIDIA L4
추론 API(bge-m3·재순위기·GLiNER) + vLLM(Qwen3-8B-AWQ)
GPU 메모리
19,648 / 23,034 MiB

0.005초	**5.75초**	**9.94초**
진단(규칙)	근거 답 중앙값	근거 답 p95(순차 100회)

보안 설정 4줄

- 앱·vLLM 은 **127.0.0.1** 에만 바인드, 접근은 SSL-VPN → ssh 터널(시연용)
- GPU 추론 API **공유 토큰**: 없거나 틀리면 401, 토큰 로그 출현 0건
- **입력 저장 0**: DB 없음, 표지 문자열 60회 전송 뒤 로그 0건
- 실행 중 모델 허브 **오프라인**, 의존성 알려진 취약점 0건(OSV, 6개 패키지)

계층	기술 · 버전 (전체는 uv.lock · ⓕ)
언어	Python 3.12.3 · JavaScript(프레임워크 없음)
API	FastAPI 0.162.0 · Uvicorn 0.54.0 · Pydantic 2.14.2
모델 실행	PyTorch 2.15.0 · sentence-transformers 6.2.0 · GLiNER 0.2.29
LLM 서빙	vLLM 0.32.0 — JSON 스키마 강제, 요청 로그 끔
시험·개발	uv · pytest 9.2.0 · Playwright · Node.js 22 · Ubuntu 24.04 · Claude Code(개발 보조)
실행	셸 스크립트 + PID 파일(Docker 안 씀)

출처: docs/EVIDENCE.md 0·6·9절 · docs/evidence/infra.md

조사한 사람이 경로를 정하고, 만든 사람이 엔진을, 검증한 사람이 안전을 책임졌습니다

김시현 법령 조사
84경로·16 공백 → **지식표 84행**
팀 공유 계약 → **정세영** 규칙 엔진·가드
검증 루프·L4 서빙 → **김대웅** 합성 평가
레드팀 세트 112건 → ↻ 평가 결과로 가드·지식표 수정
→ 재측정 `cf8d149→cacc901`

정세영 백엔드 및 AI

운영·추론 API, 규칙 엔진, 2단 가드, 생성→검증→재생성→발췌 루프, Qwen3-8B·vLLM 서빙, NCP 2대 배포·GPU 토큰

L4 1장에 모델 4종 · 19,648/23,034MiB

담당 산출물 `1664b20` `0b21e23` `da3e675` `642e5e1` · PR #3 → main `993db4f`

김시현 기획·법령조사·프런트

문제 정의·목표 사용자, 노출 경로 법령 조사, 지식표 기획, 사용자 흐름·통지 확인 잠금, 화면 개선(PR #2)

84경로 · 막을 제도 없음 16

담당 산출물 `d677ea0` `a9028c5` · PR #2 `34edc21` `83c3f63` `b8f6631` `ac7520e` `5085bcb`

김대웅 평가·보안·PT

합성 평가 세트·하네스, 다턴 시뮬레이터, 레드팀·가드 평가, 시험 계획·결과, 발표 자료

레드팀 3/84(검색·답 경로) · 조회 방법 출력 0

담당 산출물 `fbf4d15` `38a14c1` `efb3fee` `23a03c7` · PR #4 `e2b7b93` `6b354a2` `ef5ddf0` `f6ccc4f`

※ 커밋은 공용 개발 환경(정세영 계정)에서 함께 했습니다. 팀원 개인 계정 기여는 PR #2(김시현)·PR #4(김대웅)입니다. 위 해시는 각자 맡은 산출물입니다.

브랜치
`main` 통합·배포 · `feature/frontend` 화면 · `docs-v2` 문서 · 검색 답 종합 실험(로컬, 게이트 미달로 **미병합**)

PR 로만 main 에
main 최신본 합치기 → 시험 통과 → PR. PR #2 화면 → docs-v2 통합 → PR #3 로 main 병합·배포

계약은 시험으로
API 계약을 `tests/` 로 고정, GPU 없이 화면을 띄우는 모의 GPU 서버(`f2c382f`)

수치는 한 곳에서
모든 숫자의 기준 `docs/EVIDENCE.md` → 덱·제출 문서·README 가 같은 값

산출물 일관성 조사 84경로 → 지식표 84행 → 엔진 시험 84/84행 도달 → 1쪽·진단 화면의 84 — 레드팀 3/84 → 5쪽·제출 문서·README 같은 값

공개 모델·오픈소스는 그대로 쓰고 모두 밝힙니다 — 상용 AI 는 개발 보조에만, 서비스 실행 중 호출 0

구분	명칭	용도	라이선스
오픈소스	BAAI/bge-m3	임베딩·의도 분류	MIT
	BAAI/bge-reranker-v2-m3	재순위·답변 검증	Apache-2.0
	urchade/gliner_multi-v2.1	서류 위치 단서 개체명 인식	Apache-2.0
	microsoft/mdeberta-v3-base	GLiNER 백본·토크나이저	MIT
	Qwen/Qwen3-8B-AWQ	내부 LLM(미세조정 없음)	Apache-2.0
	vLLM 0.32.0	LLM 서빙	Apache-2.0 *
	PyTorch 2.15.0	모델 실행	BSD-3 계열
	transformers 5.16.1	모델 실행(의존)	Apache-2.0
	sentence-transformers 6.2.0	임베딩·재순위 추론	Apache-2.0
	FlagEmbedding 1.4.2	GPU 서버 의존성	MIT
	GLiNER 라이브러리 0.2.29	개체명 인식 추론	Apache-2.0
	FastAPI 0.162.0 · Starlette 1.10.0	운영·추론 API	MIT · BSD-3
	Uvicorn 0.54.0	ASGI 서버	BSD-3
	Pydantic 2.14.2	요청·응답 검증	MIT
	HTTPX 0.28.1	API 간 호출	BSD-3
	NumPy 2.5.4	점수 계산	BSD-3
	uv 0.12.7	패키지 관리	MIT/Apache-2.0 *
	pytest 9.2.0	자동 시험	MIT
	Playwright (Chromium)	시험·캡처, 시연 녹화(playwright-core 1.63.0)	Apache-2.0
	FFmpeg 7.0.2 (imageio-ffmpeg 0.7.0)	시연 영상 MP4 변환(개발)	BSD-2 · 바이너리 GPL-3.0
	Node.js 22	탐지기 평가(개발)	MIT *

구분	명칭	용도	라이선스
외부 API	Anthropic Claude (Claude Code)	개발 보조: 코드·조사·문서 작성, 평가·레드팀 결과 검토. **서비스 실행 중 호출 없음**	상용
	DeepSeek-V4.1-Flash (래블업 토큰 팩토리)	쉬운 말 설명 초안 42건·1차 코드 일부. **서비스 실행 중 호출 없음**	상용 API (래블업 토큰 팩토리)
	GLM-5.3-Flash (래블업 토큰 팩토리)	평가 시뮬레이터의 가상 사용자·공격자. **서비스 실행 중 호출 없음**	상용 API (래블업 토큰 팩토리)
사전 보유 코드	해당 없음	주제 공개(10-30) 뒤 새 저장소. 첫 커밋 d677ea0 2026-10-31 11:04	해당 없음
기타	법제처 국가법령정보센터 법령 원문	조문 175건 스냅샷, 근거 표시·검색	공공저작물(저작권법 제7조)
	NAVER Cloud Platform 공공기관용 서버 · L4 · SSL-VPN	배포·시연(주최 측 제공)	대회 제공 조건
	Hugging Face Hub	모델 배포처(설치 때만)	각 모델 라이선스
	Pretendard 글꼴	발표 자료	SIL OFL 1.1
	Noto Sans KR 글꼴 (Google Fonts)	제출 PDF 원문자 대체 글꼴	SIL OFL 1.1
	나눔고딕 글꼴	화면 캡처	SIL OFL 1.1
	서비스 파비콘	브라우저 탭 아이콘	팀 자체 제작(김시현), MIT
	GitHub	소스 공개·협업	GitHub 이용약관
	공식 기관 페이지·언론 보도	법령 조사·문제 근거	인용·출처 표시
	개인 보유 개발 도구 (LLM 호출 중계 등)	개발 중 외부 API 호출용. 저장소 코드에 미포함	해당 없음

실행 중 외부로 나가는 것: 빠른 나가기의 검색 이동, 112·1366·132 전화 링크뿐 · 버전은 `uv.lock`·배포 서버 실측, 라이선스는 `THIRD_PARTY_NOTICES.md`·패키지 메타데이터 대조(* 공개 저장소 표기)

몰라서·늦어서·순서를 틀려서 새는 주소 — 피해자는 놓친 제도를, 상담 현장은 첫 상담 점검표를, 정책은 막을 수 없는 16개 경로를 얻습니다

상황을 **고름** → 유출 경로·제도·**통지 위험을 앎** → 소송·이사·신고 **전에** 비공개 신청 → **서류로 새는 일 감소** (검증 예정)

피해자
흩어진 제도를 **급한 순서**로 한 화면에. 통지 경고로 역노출을 미리 앎. 서류의 위치 단서를 스스로 지움

상담 현장
인쇄한 결과를 1366·132 상담에 가져가 이어감 — **첫 상담 점검표**로 쓰임

정책
막을 제도가 없는 **16개 경로**를 근거와 함께 드러냄. 법이 바뀌면 지식표 행만 고침

지금 바로 적용할 수 있는 근거 (배포본 실측, 합성 부하)

약 200세션
L4 1장, 시간당(품질 유지 동시 2)

약 9.7원
세션당(꽉 찰 때), 약 2.2만 토큰

GPU 없이
규칙 진단 + BM25 + 체크박스로 핵심 동작

무료 법률정보 안내(법률상담 아님) · AI 문장엔 'AI 생성' 표시(인공지능기본법 제31조) · 위치 권한 요청 없음

아직 증명 안 된 것 → 다음 게이트

- 사람 검수 **0/84 → 84/84**
- 레드팀 3.6%(3/84) → **확대 세트로 재측정**
- 공개 전 TLS·인증·접근 범위·속도 제한

실제 이용자 효과는 미검증(합성 평가만). 상세 한계는 저장소에 공개

출처: docs/EVIDENCE.md 0-16·0-17 · docs/COST_LATENCY.md §3-3 · 한계 전체 docs/SUBMISSION.md ⓖ

해외도 한 번에 다 막지 못합니다 — 그래서 경로별 진단, 다음 1년은 사람 검수와 상담 현장 시범으로 증명하겠습니다

단계	할 일(산출물)	담당(안)	성공 지표 (기준선 실측 → 목표)
단기 ~3개월	쉬운 말 설명 84행 전문가 검수	김시현	검수 **0/84 → 84/84**
	레드팀 확대 세트(사칭·이주민 언어·적응형), 판정자 분리	김대웅	3.6%(3/84) 재측정 · 조회 방법 출력 0 유지
	공개 전 보안: TLS·인증·속도 제한·접근 범위, 가드 장애 시 막는 쪽 동작	정세영	공개 전 점검 항목 전부 완료
중기 ~1년	스토킹 피해자보호명령(2027-04-22 시행) 반영, 법령 갱신 = 지식표 행 단위	김시현	시행일 **전** 반영
	상담 현장 시범 1곳 — 운영 주체 후보 1366·상담소(협력은 제안 단계)	팀 전체	시범 기관 ≥1 · 놓친 제도 수 사전·사후 비교
	근거 답을 사람 라벨로 재확인	김대웅	0.956 재확인
장기 1년+	기기 안 추론(진단·단서 탐지·1차 가드)	정세영	서버 전송 = 조문 검색 질의만
	기관 발송 전 서류 점검, 84경로 분류체계 공개	팀 전체	협력 기관 수 · 정책 제안서 1건
	두 번째 보안 주제 '명의 예보'(계획): 유출 통지 뒤 내 이름으로 휴대폰·계좌·대출이 열리는 경로 진단 → 가입제한·안심차단 안내. 같은 엔진, 지식표 약 30행 추가	팀 전체	보안 예보 = 주소 예보 + 명의 예보 · 선행 조문 확인 3건

해외 유형	대표 사례	한국
대체주소	미국 대부분 주(ACP)	**없음**
등록부 차단	일본(스토커 포함)·독일·스웨덴	가정폭력만
절차별 비공개	일본 소송 비닉·영국 선거인 익명	신청해야만
기술 안전 도구	Cornell CETA·영국 Bright Sky	경로 진단 도구 못 찾음

정책 제안: 교부 제한을 스토킹·교제폭력까지 · 한 번의 제한 결정을 다른 절차에 재사용 · 빈 16경로 입법

피신한 곳은, 피신한 곳으로 남아야 합니다.

모든 수치는 합성 데이터 기준 · 법률정보 안내이며 법률상담이 아닙니다 · 긴급 112 · 상담 1366 · 132

출처: research/2026-11-01-해외레퍼런스.md · 발전방향.md · 확장계획.md · docs/EVIDENCE.md