코디세이 AI 해커톤 2026 · 주제 02 · AI 기반 정보보호 서비스

# 숨은집 지킴이

피해자의 새 주소가 새는 경로를 진단하고
막는 제도를 근거와 함께 안내하는 **피해자 본인용 AI 자가 점검 도구**

**EasyPeasy 팀** · 정세영 · 김시현 · 김대웅

ⓐ 문제·대상 ⓑ 해결·기능 ⓒ AI 기술·직접 개발 ⓓ 개발 환경 ⓔ 역할 분담 ⓕ 외부 자원 ⓖ 기대 효과·확장

github.com/codyssey-EasyPeasy/sumeunjip · 최종 커밋은 제출 파일(EasyPeasy_소스코드.txt) 기준 · 모든 평가 수치는 합성 데이터 기준

Ⓐ 문제 정의 및 목표 사용자

# 피신은 했지만, 주소는 서류를 타고 새어 나갑니다

**2026.9 광주** 보도

**이혼 소장**으로 피신 주소가 드러난 뒤 살해.
주소 비공개 신청은 하지 않은 상태

**2026.10 대구** 보도

잠정조치 결정문 가해자 주소란에 피해자 **새 주소**가 적혀 전달됨

**4.5만 건**
스토킹 신고 2025
(2024년 3.2만)

**10.5만 건**
교제폭력 신고 2025
(2024년 8.8만)

**3천여 건**
연 주민등록 열람제한
(가정폭력 상담 18~20만)

## 문제를 겪는 대상

| | |
|---|---|
| **1차 사용자** | 스토킹·가정폭력·교제폭력·성폭력 **피해자 본인** — 막 이사했거나 소송 중, 법률 비전문가, 기기를 감시당할 수 있음 |
| 2차 사용자 | 피해자의 가족·지인 |
| 다루지 않음 | 다른 사람의 위치를 **찾으려는** 사람 → 거절 + 보호 제도 안내 |

**84**
주소가 드러날 수 있는 기록·절차 경로(6개 영역)

**16**
막는 제도가 **없는** 경로 (+시행 예정 1)

## 막는 제도가 있어도 새는 이유

- **신청주의** — 신청해야만 작동, 법원 사전 안내 의무 없음 (민사소송법 제163조 제2항)
- **유형별 공백** — 교부 제한·보호명령은 가정폭력 전용. 비가족 스토킹·교제폭력엔 없음
- **역노출** — 제한을 신청하면 그 사실이 가해자에게 통지 (주민등록법 제29조 제7항 후단 등)

사례·통계: 경인일보·경북매일·헤럴드경제·서울신문 보도, `research/2026-10-31-정보조사.md` 5절(보도 기준, 원자료 미확인). 원인: 같은 문서 1절. 84·16: `data/knowledge.json`. 대상 변경: 상담사용 → 피해자 본인(`docs/SPEC.md` §7)

ⓑ 해결 방안 및 주요 기능 (1/2)

# 피해자가 직접 쓰는 '주소 노출 점검표'

이름·주소 없이 상황만 고르거나 말로 적으면, **새 주소가 샐 수 있는 경로**와 **그 경로를 막는 제도**를 근거 조문·신청처·서류·통지 경고와 함께 **급한 순서**로 보여 줍니다.

**1 안전 확인**
긴급 연락처, 시크릿 창 권장, 빠른 나가기 위치

→

**2 상황 입력**
유형 + 상황 체크, 또는 말로 적기 → AI 미리 선택 → **본인 확인**

→

**3 진단 결과**
급한 순서 체크리스트, 통지 경고 확인, 잔여 위험, 인쇄

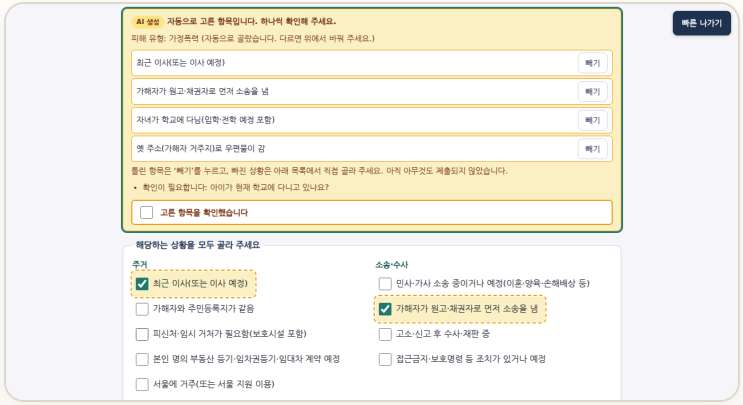
→

**4 서류 점검**
위치 단서 표시, 안전한 문장 제안

| 핵심 기능 | 하는 일 | AI |
|---|---|---|
| **① 노출 경로 진단** | 피해 유형 4 + 상황 항목 30 → 84개 경로 중 해당하는 것을 급한 순서로, '지금 먼저 할 일' 최대 5건 | 안 씀 (규칙 엔진) |
| **② 막는 제도 안내** | 근거 조문(시행일)·신청처·서류·한계·확인 수준. 통지되는 제도는 **확인 체크 뒤에만** 신청 방법. 잔여 위험 따로 | 안 씀 |
| **③ 말로 설명하기** | 자유 서술 → 체크 항목 미리 선택. 주입 지시문 제거, 근거 낱말 없는 항목 버림 | 내부 LLM |
| **④ 근거 답** | 지식표·공개 조문만으로 답. 생성 → 문장별 검증 → 1회 재생성 → 원문 발췌 | 내부 LLM + 재순위 |
| **⑤ 서류 점검·다시 쓰기** | 주소·학교·직장·차량·전화 단서 표시(1단계는 브라우저 안에서만), 원문과 정렬되는 안전한 문장 제안 | 규칙 + GLiNER + LLM |
| **⑥ 안전 장치** | 빠른 나가기(버튼·Esc 두 번), 2단 가드(타인 찾기 거절 + 보호 대안 + 1366·132·112), 입력 저장 0 | 규칙 + 임베딩 |

출처: docs/OVERVIEW.md 5–7절 · docs/SPEC.md §11 · app/engine.py

# 배포본 화면 (합성 입력)




③ AI 가 미리 고른 항목 — 본인 확인 뒤 제출




①② 진단 결과 '지금 먼저 할 일'




② 통지 경고 — 확인 체크 전엔 신청 방법이 가려짐




④ 근거 답 — 'AI 생성 + 문장별 근거 확인'




⑤ 서류 점검 — 단서 색칠과 바꾸는 방법




⑤ 다시 쓰기 — 원래 문장 / 바꾼 문장

출처: docs/screens/ (Playwright 촬영, docs/evidence/README.md)

© 활용 AI 기술 및 직접 개발 범위 (1/2)

# 공개 모델 4종은 그대로, 판단·검증은 직접 만들었습니다

| 모델 (외부·그대로) | 적용 기능 | 적용 방식 (직접 만든 부분) |
|---|---|---|
| **BAAI/bge-m3** MIT | 조문 검색, 가드 의도 점수 | 노출 가능 조문 131건 임베딩 → 상위 30. 가드는 자체 시드 max-sim 점수를 **신호 하나로만**(0.16 초과 + 타인 지시어 + 보호 맥락 없음일 때만 거절 근거) |
| **bge-reranker-v2-m3** Apache-2.0 | 재순위, 답 근거 확인 | 30 → 5. 답 문장마다 근거 조각 3개, 0.01 미만이면 '근거 없음' |
| **gliner_multi-v2.1** Apache-2.0 | 서류 정밀 점검 | 자체 라벨 매핑, 700자 조각 나눔·병합, 정규식 결합 |
| **Qwen3-8B-AWQ** + vLLM Apache-2.0 | 상황 정리·근거 답·다시 쓰기·검증기 | thinking 끔, **JSON 스키마 강제 출력**. 프롬프트·전후처리·검증 루프 전부 자체. 미세조정 없음 |

## 자체 알고리즘

- **규칙 진단 엔진** — 84행 결정적 판정, AI 없음, 0.005초
- **2단 가드** — 정규화(NFKC·자모·디코딩 변형) → 규칙·구문 → 임베딩, 5등급, 다턴 결합, 앱·GPU 두 번
- **근거 답 루프** — 생성 → 규칙·재순위·Qwen 검증 → 1회 재생성 → 발췌(12초 예산)
- **공통 출력 가드** — 프롬프트 유출·금지 조문(해시 24,995)·과잉 약속·목록 밖 인용·반복
- **다시 쓰기 정렬** — 새 숫자·이름·장소, 정렬 비율 0.6 미만이면 규칙 치환

## 런타임 외부 AI API 호출 0

LLM 은 GPU 서버에 직접 띄운 Qwen 하나뿐. 실패해도 다른 LLM 으로 넘기지 않고 체크박스 방식으로 계속. 실행 중 `HF_HUB_OFFLINE=1`.

우리가 만든 API — 운영: /api/diagnose · search · doccheck · intake · answer · rewrite · flags · features · health / 추론: /embed · /rerank · /ner · /intent · /llm/{intake,answer,rewrite}

출처: docs/SPEC.md §11 · gpu/server.py · gpu/verify.py · app/guard.py · THIRD_PARTY_NOTICES.md

© 활용 AI 기술 및 직접 개발 범위 (2/2)

# 직접 만든 것 · 가져다 쓴 것 · 개발에 쓴 AI

## 직접 만든 것 (wc -l)

| | |
|---|---|
| 규칙 엔진 | engine.py 203 |
| 지식표 84행 (자체 법령 조사, 근거 224건) | knowledge.json |
| 2단 가드·정규화 | guard.py 1,045 |
| 검증 루프·출력 가드 | verify 582 · llm 693·497 |
| 운영·추론 API | main 501 · server 613 |
| 웹 화면·단서 탐지 | app.js 1,381 · detect 126 |
| 평가·시뮬레이터·레드팀 | tools 3,626 + sim 1,946 |
| 자동 시험 (572 · 188 passed) | tests 3,359 · 1,722 |

## 그대로 쓴 것

- 모델 4종 — 미세조정 없음
- vLLM · PyTorch · FastAPI 등
- 법령 원문 174건 (법제처)
- 서버 2대·L4·SSL-VPN (주최 측 NCP)

## 개발에 쓴 AI 서비스엔 없음

- **Claude**(Claude Code, Opus): 팀원 지시 아래 코딩·조사·문서 보조로 **폭넓게**. 설명 41건+수정 12건·J28
- **DeepSeek-V4.1-Flash**: 설명 42/84건 초안, 1차 코드 일부 초안(공개 법령만)
- **GLM-5.3-Flash**: 평가 때 합성 사용자·공격자 역할만
- 셋 다 **런타임 호출 0**. 설명 84건 사람 검수 전 → 'AI 생성(검수 전)'

**56/56**
진단 꼭 나올 제도, 잘못 적용 0 results.json

**0.964**
조문 검색 Recall@5 (BM25 0.800) retrieval_baseline.md

**0.823**
서류 단서 탐지 F1 (1단계 0.682→2단계 0.748→결합) results.json

**0.956**
근거 답 45문항 정답률 results_llm.json

**35/35 · 0/25**
찾기 질문 거절 · 정상 질문 오거절 (운영 앱) results_app_llm.json

**5.4→2.7%**
레드팀 121개 서비스 경로 성공률, 조회 방법 출력 0 redteam-summary.md

모든 수치는 **합성 데이터 기준**. 남은 문제: 다턴 시뮬레이션 자기 보호 질문 오거절 18건/14대화(notice_calibration_summary.md). 근거 답 근거 없는 문장 3.6%→0 은 같은 검증기로 잰 값(독립 판정 아님).

출처: data/README.md · docs/SPEC.md §11.7 · data/eval/*

◎ 개발 환경 및 기술 스택

# Python 3.12 · FastAPI · vLLM, GPU 1장 위의 자체 호스팅

| 계층 | 기술 · 버전 |
|---|---|
| 언어 | Python 3.12.3 · JavaScript(바닐라) · HTML/CSS |
| 패키지 | uv (`uv.lock`, 개발 기기 0.12.7) |
| 운영 API | FastAPI 0.162.0 · Starlette 1.10.0 · Uvicorn 0.54.0 · Pydantic 2.14.2 · HTTPX 0.28.1 |
| 추론 API | sentence-transformers 6.2.0 · GLiNER 0.2.29 · PyTorch 2.15.0 · transformers 5.16.1 · NumPy 2.5.4 |
| LLM 서빙 | vLLM 0.32.0 — JSON 스키마 강제, 요청·생성 로그 끔 |
| 모델 | bge-m3 · bge-reranker-v2-m3 · gliner_multi-v2.1 · Qwen3-8B-AWQ |
| 웹 | 프레임워크 없음, 외부 CDN·쿠키·localStorage 없음 |
| 시험·평가 | pytest 9.2.0 · Node.js 22 · 자체 시뮬레이터 · Playwright(캡처) |
| 실행 | 셸 스크립트 + PID 파일 (Docker·systemd 안 씀) |

## 인프라 — 주최 측 제공 NCP

**운영 서버** Xeon Gold 5220 2vCPU · 7.8GiB — 127.0.0.1:8080

**GPU 서버** Xeon Silver 4416+ 4vCPU · 47GiB · **NVIDIA L4** — :8000 추론 API, 127.0.0.1:8001 vLLM

GPU 메모리 13,948 + 5,686 = **19,648** / 23,034MiB (23:33)

접근: SSL-VPN → ssh 터널 (시연용, TLS 없음)

## 응답 시간 (서버 안 중앙값, 합성 5회)

진단 **0.005s** · 검색 0.945s · 상황 정리 1.827s · 근거 답 5.745s · 다시 쓰기 2.366s

부하 시험 없음. 최신은 docs/COST_LATENCY.md

출처: uv.lock · docs/evidence/infra.md §1–3·§7 · infra-2026-10-31-night.md 1·2·5절 · deploy-2026-11-01.md

ⓔ 팀원별 역할 분담

# 세 사람, 세 영역 — 담당 업무와 기여 내용

| 이름 · 역할 | 담당 업무 | 기여 내용 (저장소 산출물) |
|---|---|---|
| **정세영**<br>백엔드 및 AI | 운영·추론 API 설계와 구현, 내부 LLM 도입, 입력·출력 가드와 답 검증 루프, 서버 배포·운영 | 규칙 진단 엔진 `app/engine.py` · 2단 입력 가드 `app/guard.py` · 조문 검색·BM25 대체 · 추론 서버 `/embed`·`/rerank`·`/ner`·`/intent`·`/llm/*` · 생성→검증→재생성→발췌 루프·출력 가드 `gpu/verify.py` · Qwen3-8B·vLLM 서빙 · NCP 2대 배포, L4 메모리 19,648/23,034 MiB · GPU API 토큰·HF 오프라인 |
| **김시현**<br>기획 및 법령조사<br>프런트엔드 | 문제 정의·목표 사용자 설정, 주소 노출 경로 법령 조사, 지식표 기획, 웹 화면과 사용자 흐름 | 정보조사 `research/…정보조사.md` — 6개 영역 **84개 노출 경로**, 막는 제도 없는 16개, 통지 12개 · 지식표 84행 기획 `data/knowledge.json` · 근거 조문 174건 범위 선정 · 사용자 흐름(안전 확인 → 입력 → 진단 → 서류 점검), 피해자 본인 사용 전환 · 웹 화면 `web/` — 빠른 나가기, 통지 확인 잠금, 모바일, 안전 안내 팝업 |
| **김대웅**<br>평가·보안<br>PT 자료 제작 | 합성 평가 데이터·평가 하네스, 다턴 시뮬레이터, 레드팀·가드 평가, 시험 계획·결과, 발표 자료 | 합성 평가 세트 `data/eval/`(시나리오 20·서류 30·서술 20·답 45·검색 60·가드 70·보정 60) · 평가 하네스 `tools/eval*.py` · 다턴 시뮬레이터 `tools/sim/` · **레드팀 121개 공격** 5.4% → 2.7%, 가드 평가 35/35 · 오거절 0/25 · `TEST_PLAN`·`TEST_RESULTS` · 차트·화면 캡처 · 발표 자료 `pt/` |

### 브랜치

`main` 통합·배포 기준 · `feature/frontend` 화면 · `docs`·`docs-v2` 제출 문서

### PR 로 합치기

작업 브랜치에 `main` 최신본을 합치고 시험 통과 뒤 PR 로 병합. `main` 직접 push 금지

### 계약은 시험으로

화면·API 계약을 `tests/` 로 고정, GPU 없이 화면을 띄우는 모의 GPU 서버 제공

AI 도구가 맡은 부분(코딩·조사·문서 보조 Claude, 설명 초안 DeepSeek, 평가 역할극 GLM)은 ⓒ·ⓕ 에 따로 적음 · 협업 규칙: `docs/LOCAL_DEV.md`

# 외부 자원 활용 내역 — 참가자 가이드 표 형식 그대로, 두 단으로 나눠 실음

| 구분 | 명칭 | 용도 | 라이선스 |
|---|---|---|---|
| 오픈소스 | BAAI/bge-m3 | 임베딩·의도 분류 | MIT |
| | BAAI/bge-reranker-v2-m3 | 재순위·답변 검증 | Apache-2.0 |
| | urchade/gliner_multi-v2.1 | 서류 위치 단서 개체명 인식 | Apache-2.0 |
| | Qwen/Qwen3-8B-AWQ | 내부 LLM(미세조정 없음) | Apache-2.0 |
| | vLLM 0.32.0 | LLM 서빙 | Apache-2.0 * |
| | PyTorch 2.15.0 | 모델 실행 | BSD-3 계열 |
| | transformers 5.16.1 | 모델 실행(의존) | Apache-2.0 |
| | sentence-transformers 6.2.0 | 임베딩·재순위 추론 | Apache-2.0 |
| | FlagEmbedding 1.4.2 | GPU 서버 의존성 | MIT |
| | GLiNER 라이브러리 0.2.29 | 개체명 인식 추론 | Apache-2.0 |
| | FastAPI 0.162.0 · Starlette 1.10.0 | 운영·추론 API | MIT · BSD-3 |
| | Uvicorn 0.54.0 | ASGI 서버 | BSD-3 |
| | Pydantic 2.14.2 | 요청·응답 검증 | MIT |
| | HTTPX 0.28.1 | API 간 호출 | BSD-3 |
| | NumPy 2.5.4 | 점수 계산 | BSD-3 |
| | uv 0.12.7 | 패키지 관리 | MIT/Apache-2.0 * |
| | pytest 9.2.0 | 자동 시험 | MIT |
| | Playwright (Chromium) | 시험·화면 캡처 | Apache-2.0 |
| | Node.js 22 | 탐지기 평가(개발) | MIT * |

| 구분 | 명칭 | 용도 | 라이선스 |
|---|---|---|---|
| 외부 API | Anthropic Claude (Claude Code) | 개발 보조: 코드·조사·문서 작성. **서비스 실행 중 호출 없음** | 상용 |
| | DeepSeek-V4.1-Flash (래블업 토큰 팩토리) | 쉬운 말 설명 초안 42건·1차 코드 일부. **서비스 실행 중 호출 없음** | 상용 API (래블업 토큰 팩토리) |
| | GLM-5.3-Flash (래블업 토큰 팩토리) | 평가 시뮬레이터의 가상 사용자·공격자. **서비스 실행 중 호출 없음** | 상용 API (래블업 토큰 팩토리) |
| 사전 보유 코드 | 해당 없음 | 주제 공개(10-30) 뒤 새 저장소. 첫 커밋 `d677ea0` 2026-10-31 11:04 | 해당 없음 |
| 기타 | 법제처 국가법령정보센터 법령 원문 | 조문 174건 스냅샷, 근거 표시·검색 | 공공저작물(저작권법 제7조) |
| | NAVER Cloud Platform 공공기관용 서버 · L4 · SSL-VPN | 배포·시연(주최 측 제공) | 대회 제공 조건 |
| | Hugging Face Hub | 모델 배포처(설치 때만) | 각 모델 라이선스 |
| | Pretendard 글꼴 | 발표 자료 | SIL OFL 1.1 |
| | 나눔고딕 글꼴 | 화면 캡처 | SIL OFL 1.1 |
| | 공식 기관 페이지·언론 보도 | 법령 조사·문제 근거 | 인용·출처 표시 |
| | 개인 보유 개발 도구 (LLM 호출 중계 등) | 개발 중 외부 API 호출용. 저장소 코드에 미포함 | 해당 없음 |

버전: `uv.lock` · `infra-2026-10-31-night.md` 5절(배포 서버 실측). 라이선스: `THIRD_PARTY_NOTICES.md`(모델은 HF 모델 카드) + 로컬 패키지 메타데이터 대조. * 로컬 대조 못 해 공개 저장소 표기를 따름. 서비스 실행 중 외부로 나가는 것은 빠른 나가기의 Google 검색 이동과 112·1366·132 전화 링크뿐. 공공데이터포털 법제처 API 는 조건만 확인, 미사용.

◎ 기대 효과 및 확장 가능성 (1/2)

# 흩어진 신청주의 제도를, 피해자가 놓치지 않게

### 피해자

제도를 **급한 순서**로 한 화면에. 통지 경고로 역노출을 미리 앎. 제출 서류의 위치 단서를 스스로 지움.

실제 이용자 효과는 미검증(합성 56/56)

### 상담 현장

인쇄한 결과를 1366·132 상담에 가져가 이어감. '초기 상담부터 능동 안내'에 쓸 체크리스트.

성평등가족부 대응(2026-09-05) 보도 [2차]

### 정책

막을 제도가 없는 **16개 경로**를 근거와 함께 드러냄. 법이 바뀌면 지식표 행만 고침.

직권보호안 등 계류(진행 미확인)

### 실제 적용 가능성

- **이미 배포·실측** — L4 1장에 모델 4종, 배포 해시 = 저장소
- **GPU 없이도 핵심 동작** — 규칙 진단 + BM25 + 체크박스 방식
- **비용(추정)** — NCP 공공기관 정가 약 140만 원/월, GPU 83% (COST_LATENCY.md, 작성 시점)
- **법적 경계** — 무료 일반 정보, 'AI 생성' 표시(인공지능기본법 제31조)

### 공개 전 반드시 할 일 (숨기지 않음)

- TLS · 속도 제한 · 인증 (지금은 ssh 터널 시연)
- **GPU 8000 포트가 VPN 사용자에게 열림** — 토큰 인증은 적용(무토큰 401), 접근 범위 좁히기는 미적용
- 자기 보호 질문 오거절 18건/14대화, 생활권 단서 0/11
- 쉬운 말 설명 84건 전문가 검수, 시험 결함 xfail 앱 36 · GPU 4 수정

출처: README.md 한계 절 · infra-2026-10-31-night.md 7절 · deploy-2026-11-01.md · docs/COST_LATENCY.md · docs/TEST_RESULTS.md

# 추가 개발 방향

### 단기 — 공개 전

- TLS·속도 제한·인증
- GPU 포트 접근 좁히기
- 시험 실패 항목 수정
- 실제 이용자 사용성 평가

### 중기 — 데이터·대상 확장

- 법령 자동 갱신 — 공공데이터포털 법제처 API(자동 승인·무료 확인)
- 찾기쉬운 생활법령 연계
- 시행 예정 제도 자동 전환(2027-04-22)
- 상담사 모드 — 접근 코드 기능은 이미 구현, 기본 꺼짐

### 장기 — 연계·정책

- 1366·지원기관 연계(제안)
- 다국어 안내(제안)
- 공백 경로 정책 제안 — 미국 주소비밀유지 프로그램·영국 익명 등록·일본 지원조치 비교

막는 제도는 있는데 **몰라서·늦어서·순서를 틀려서** 새는 주소를 줄입니다. 판단은 결정적 규칙이, 설명은 자체 호스팅 LLM 이, 거절과 검증은 두 겹의 가드가 맡습니다.

모든 수치는 합성 데이터 기준 · 법률정보 안내이며 법률상담이 아닙니다 · 긴급 112 · 1366 · 132

출처: research/2026-10-31-정보조사.md 6·8절 · data/knowledge.json · docs/SPEC.md §7